


Dossier de synthèse — POC Electio-Analytics

MSPR TPRE813 · Bloc 3 · Big Data & Business Intelligence



EPSI Toulouse — M1 EISI · 2025–2026

Réaliser par :

Antoine Cerdan

François Talaban

Gabriel Karakhanyan

Kévin Ferraretto

*Document rédigé dans le cadre de la MSPR TPRE813 — Bloc 3 RNCP35584 Données : data.gouv.fr, INSEE — Traitement : Python (Pandas, Scikit-learn), SQLite, Google Colab
Code source : dépôt Git partagé*

Table des matières

1. Contexte et objectif	3
2. Justification du choix géographique	3
3. Choix des indicateurs	3
4. Démarche et méthodes employées.....	5
Étape 1 — Identification des sources de données	5
Étape 2 — Définition du périmètre.....	5
Étape 3 — ETL sur Google Colab	5
Étape 4 — Centralisation sur dépôt Git	8
Étape 5 — Uniformisation finale	8
Étape 6 — Chargement en base SQLite	8
Étape 7 — Visualisation et modélisation	8
5. Modèle Conceptuel de Données.....	8
6. Exploration des données	9
Matrice de corrélation — résultats clés	9
Distribution des variables	11
Évolution du chômage national.....	11
Nuages de points — corrélations visuelles.....	12
7. Modèles prédictifs testés	12
Modèles comparés	13
Implémentation	13
8. Résultats et visualisations.....	14
Vue 1 — Carte & Indicateurs	14
Vue 2 — Résultats T1 2022	15
Vue 3 — Corrélations	16
Prédictions à 1, 2 et 3 ans.....	16
9. Accuracy — pouvoir prédictif.....	19
Définition des métriques utilisées	19
Limites et perspectives	20
Tableau récapitulatif	20
10. Réponses aux questions d'analyse	21
11. Recommandations	23

1. Contexte et objectif

Electio-Analytics est une startup spécialisée dans le conseil stratégique pour les campagnes électorales. Son besoin est de disposer d'une capacité de **prévision des tendances électorales à moyen terme (1 à 3 ans)** à partir d'indicateurs socio-économiques publics.

Notre mission consiste à réaliser une **preuve de concept (POC)** démontrant la faisabilité d'un modèle prédictif corrélant des indicateurs territoriaux (chômage, criminalité, démographie, activité économique) avec les résultats électoraux passés, afin d'anticiper les tendances futures.

2. Justification du choix géographique

Périmètre retenu : le département français

Après analyse des sources de données disponibles, le **département** a été retenu comme maille géographique de référence pour les raisons suivantes :

Disponibilité et cohérence des données L'ensemble des jeux de données publics exploités (data.gouv.fr, INSEE) sont systématiquement disponibles à l'échelle départementale. Cette maille est le niveau de granularité le plus fin pour lequel tous nos indicateurs sont simultanément renseignés et comparables.

Équilibre volume / représentativité - Une maille **trop fine** (commune, arrondissement) aurait produit des jeux de données fragmentés, avec de nombreuses valeurs manquantes et des résultats difficilement généralisables. - Une maille **trop large** (région) aurait lissé les disparités territoriales et réduit la puissance statistique du modèle. - Le département offre **96 observations** (France métropolitaine), suffisantes pour entraîner et valider un modèle de machine learning supervisé.

Pertinence électorale Le découpage départemental correspond aux circonscriptions de référence pour les élections présidentielles et législatives, ce qui garantit une cohérence directe entre nos données socio-économiques et les résultats électoraux exploités.

3. Choix des indicateurs

Les indicateurs ont été sélectionnés selon deux critères : leur **citation explicite dans le cahier des charges** d'Electio-Analytics et leur **potentiel d'influence sur les comportements de vote**, documenté dans la littérature en science politique.

Indicateurs retenus

Indicateur	Source	Couverture	Justification
Taux de chômage	INSEE / data.gouv.fr	1982–2025	Indicateur économique central, lié au mécontentement social et aux votes protestataires
Criminalité (16 types)	data.gouv.fr / Ministère Intérieur	2016–2025	Influence les préoccupations sécuritaires, moteur de vote pour les candidats à programme sécuritaire
Démographie (population, communes)	INSEE	2018–2021	L'urbanisation est un facteur structurant du vote : les métropoles votent différemment des zones rurales
Activité économique (nb d'entreprises)	INSEE	2012–2024	Le tissu entrepreneurial reflète la vitalité économique locale et la composition socio-professionnelle

Indicateurs non retenus (manque de données)

- **Taux de pauvreté** : données disponibles mais non encore intégrées dans la base, identifié comme piste d'enrichissement
- **Vie associative** : données parcellaires, difficilement agréables à l'échelle départementale
- **Dépenses publiques locales** : complexité de normalisation, hors périmètre du POC

4. Démarche et méthodes employées

La démarche adoptée suit un **pipeline ETL structuré en 7 étapes**, garantissant la traçabilité et la reproductibilité du processus.

[Sources publiques] → [ETL Colab] → [CSV normalisés] → [Git] → [SQLite] → [Dashboard / ML]

Étape 1 — Identification des sources de données

Recherche et sélection des jeux de données publics pertinents sur : - **data.gouv.fr** : résultats électoraux, criminalité, chômage - **INSEE** : démographie, entreprises, données socio-économiques

Étape 2 — Définition du périmètre

Cadrage du projet sur les **96 départements métropolitains**, sélection des indicateurs et des périodes temporelles disponibles. Ce cadrage conditionne l'ensemble des traitements suivants.

Étape 3 — ETL sur Google Colab

Réalisation des traitements d'extraction, transformation et chargement (ETL) sur **Google Colab**, choisi pour sa capacité à permettre le **travail collaboratif en équipe** sans contrainte d'environnement local.

Opérations réalisées : - Téléchargement et lecture des fichiers CSV sources - Nettoyage : suppression des doublons, gestion des valeurs nulles, correction des encodages - Normalisation des noms de colonnes (snake_case, suppression des accents) - Harmonisation des codes département (format 2 caractères, gestion des cas 2A/2B) - Calcul des taux dérivés (taux pour mille à partir des effectifs bruts et des populations INSEE)

```
from google.colab import drive
import pandas as pd
import numpy as np
import os
import re

drive.mount('/content/drive', force_remount=True)

... Mounted at /content/drive

folder = '/content/drive/MyDrive/MSPR CHOMAGE'
fichier_chomage = f'{folder}/taux_chomage_global_depart_region.xlsx'

df_valeurs = pd.read_excel(fichier_chomage, sheet_name='valeurs_trimestrielles')

print(f'Shape brut : {df_valeurs.shape}')
print('Colonnes fixes :', list(df_valeurs.columns[:5]))
print('Premières colonnes temporelles :', list(df_valeurs.columns[4:8]))
print('Dernières colonnes temporelles :', list(df_valeurs.columns[-4:]))

... Shape brut : (115, 180)
Colonnes fixes : ['Libellé', 'idBank', 'Dernière mise à jour', 'Période', '1982-T1']
Premières colonnes temporelles : ['1982-T1', '1982-T2', '1982-T3', '1982-T4']
Dernières colonnes temporelles : ['2025-T1', '2025-T2', '2025-T3', '2025-T4']
```

Extract

```
df_codes = pd.read_excel(fichier_chomage, sheet_name='codes')
print('Légende des codes spéciaux :')
print(df_codes.dropna())
```

Légende des codes spéciaux :

Codes	Unnamed: 1
1	Q Couvert par le secret statistique
2	E Estimation
3	F Prévision
4	P Provisoire
5	SD Valeur semi-définitive
6	R Révision
7	A Valeur normale
8	N Valeur non significative
9	O Valeur manquante
10	U Valeur atypique

```
fichier_dept = f'{folder}/departement.csv'
```

```
df_dept = pd.read_csv(
    fichier_dept,
    header=None,
    names=['num', 'code_dept', 'nom_dept', 'nom_dept_maj', 'nom_dept_min', 'soundex'],
    dtype=str
)
```

```
df_dept['code_dept'] = df_dept['code_dept'].str.zfill(2)
```

```
print(f'Référentiel : {df_dept.shape[0]} départements')
print(df_dept.head(5).to_string())
```

Référentiel : 101 départements

	num	code_dept	nom_dept	nom_dept_maj	nom_dept_min	soundex
0	1	01	Ain	AIN	ain	A500
1	2	02	Aisne	ATISNE	aisne	A250
2	3	03	Allier	ALLIER	allier	A400
3	4	04	Haute-Alpes	HAUTES ALPES	hautec.alpes	U27419

```
df_long['qualite'] = 'réel' # valeur par défaut
df_long.loc[df_long['taux_chomage'] == 'Q', 'qualite'] = 'secret'
df_long.loc[df_long['taux_chomage'] == 'E', 'qualite'] = 'estimation'
df_long.loc[df_long['taux_chomage'] == 'F', 'qualite'] = 'prévision'

# Conversion en numérique (les codes Q/E/F deviennent NaN)
df_long['taux_chomage'] = pd.to_numeric(df_long['taux_chomage'], errors='coerce')

print('Répartition des qualités de données :')
print(df_long['qualite'].value_counts())
print(f'\nValeurs manquantes (taux_chomage) : {df_long["taux_chomage"].isna().sum()}')
```

Répartition des qualités de données :

```
qualite
réel    20240
Name: count, dtype: int64
```

Valeurs manquantes (taux_chomage) : 640

```
df_meta_clean = df_meta[['idBank', 'Zone géographique']].copy()
df_meta_clean.columns = ['idBank', 'zone_geo']
```

```
df_long = df_long.merge(df_meta_clean, on='idBank', how='left')
```

```
print('Exemple après jointure métadonnées :')
print(df_long[['zone_geo', 'trimestre', 'taux_chomage', 'qualite']].head(5).to_string())
```

Exemple après jointure métadonnées :

	zone_geo	trimestre	taux_chomage	qualite
0	France métropolitaine	1982-T1	6.7	réel
1	Île-de-France	1982-T1	5.6	réel
2	Centre-Val de Loire	1982-T1	5.7	réel

```
df_annuel = (
    df_dept_long[
        (df_dept_long['qualite'].isin(['réel', 'estimation'])) &
        (df_dept_long['taux_chomage'].notna())
    ]
    .groupby(['code_dept_extrait', 'nom_dept', 'annee'], as_index=False)
    .agg(
        taux_chomage_moyen = ('taux_chomage', 'mean'),
        taux_chomage_min = ('taux_chomage', 'min'),
        taux_chomage_max = ('taux_chomage', 'max'),
        nb_trimestres = ('taux_chomage', 'count')
    )
    .round({'taux_chomage_moyen': 2, 'taux_chomage_min': 2, 'taux_chomage_max': 2})
)

df_annuel = df_annuel.rename(columns={
    'code_dept_extrait': 'code_dept',
    'nom_dept': 'libelle_dept'
})

print(f'Dataset annuel : {df_annuel.shape[0]} lignes x {df_annuel.shape[1]} colonnes')
print(f'Période couverte : {df_annuel["annee"].min()} → {df_annuel["annee"].max()}')
print(df_annuel[df_annuel['code_dept'] == '31'].tail(10).to_string())
```

Dataset annuel : 4136 lignes x 7 colonnes

Période couverte : 1982 → 2025

	code_dept	libelle_dept	annee	taux_chomage_moyen	taux_chomage_min	taux_chomage_max	nb_trimestres
1310	31	Haute-Garonne	2016	10.10	9.9	10.4	4
1311	31	Haute-Garonne	2017	9.20	8.6	9.5	4
1312	31	Haute-Garonne	2018	8.55	8.2	8.8	4
1313	31	Haute-Garonne	2019	8.05	7.9	8.3	4
1314	31	Haute-Garonne	2020	7.98	7.1	8.9	4
1315	31	Haute-Garonne	2021	8.10	7.6	8.5	4
1316	31	Haute-Garonne	2022	7.30	7.2	7.6	4
1317	31	Haute-Garonne	2023	7.30	7.1	7.5	4
1318	31	Haute-Garonne	2024	7.58	7.5	7.7	4
1319	31	Haute-Garonne	2025	8.32	8.0	8.7	4

```

1 def extraire_code_dept(zone):
    """Extrait le code département si la zone est de la forme 'XX - Nom'."""
    match = re.match(r'^([0-9]{2}[A-B]?)\s*-\s*(.+)$', str(zone))
    if match:
        return match.group(1).zfill(2), match.group(2).strip()
    return None, None

    df_long[['code_dept_extrait', 'nom_dept_extrait']] = df_long['zone_geo'].apply(
        lambda z: pd.Series(extraire_code_dept(z))
    )

    # DataFrame uniquement départements (hors DOM pour le POC métropole)
    DEPTS_DOM = ['971', '972', '973', '974']

    df_dept_long = df_long[
        df_long['code_dept_extrait'].notna() &
        ~df_long['code_dept_extrait'].isin(DEPTS_DOM)
    ].copy()

    # DataFrame régions (pour analyses complémentaires)
    df_region_long = df_long[
        df_long['code_dept_extrait'].isna() &
        ~df_long['zone_geo'].isin(['France métropolitaine', 'France hors Mayotte'])
    ].copy()

    print(f'Lignes départements (métropole) : {df_dept_long.shape[0]}')
    print(f'Lignes régions : {df_region_long.shape[0]}')
    print(f'Nb départements uniques : {df_dept_long["code_dept_extrait"].nunique()}')

... Lignes départements (métropole) : 16544
Lignes régions : 3344
Nb départements uniques : 94

1 df_dept_long = df_dept_long.merge(
    df_dept[['code_dept', 'nom_dept', 'num']],
    left_on='code_dept_extrait',

```

Transform

```

COLS_EXPORT_TRIMES = [
    'code_dept_extrait', 'nom_dept_extrait', 'annee',
    'trimestre_num', 'trimestre', 'taux_chomage', 'qualite'
]

df_trimes_clean = (
    df_dept_long[COLS_EXPORT_TRIMES]
    .rename(columns={
        'code_dept_extrait': 'code_dept',
        'nom_dept_extrait': 'libelle_dept'
    })
    .sort_values(['code_dept', 'annee', 'trimestre_num'])
    .reset_index(drop=True)
)

print(f'Vue trimestrielle : {df_trimes_clean.shape[0]} lignes')
print(df_trimes_clean[df_trimes_clean['code_dept'] == '31'].tail(8).to_string())

Vue trimestrielle : 16544 lignes
   code_dept  libelle_dept  annee  trimestre_num  trimestre  taux_chomage  qualite
5272      31  Haute-Garonne  2024             1   2024-T1           7.5    réel
5273      31  Haute-Garonne  2024             2   2024-T2           7.5    réel
5274      31  Haute-Garonne  2024             3   2024-T3           7.6    réel
5275      31  Haute-Garonne  2024             4   2024-T4           7.7    réel
5276      31  Haute-Garonne  2025             1   2025-T1           8.0    réel
5277      31  Haute-Garonne  2025             2   2025-T2           8.2    réel
5278      31  Haute-Garonne  2025             3   2025-T3           8.4    réel
5279      31  Haute-Garonne  2025             4   2025-T4           8.7    réel

output_annuel = f'{folder}/chomage_dept_annuel_clean.csv'
df_annuel.to_csv(output_annuel, index=False, encoding='utf-8-sig')
print(f'Exporté : {output_annuel}')
print(f'   {df_annuel.shape[0]} lignes | {df_annuel.shape[1]} colonnes')

Exporté : /content/drive/MyDrive/MSPR CHOMAGE/chomage_dept_annuel_clean.csv
4136 lignes | 7 colonnes

```

Load

Notebook ETL Google Colab Capture : pipeline ETL dans Google Colab pour la variable du chômage

Étape 4 — Centralisation sur dépôt Git

Les CSV nettoyés sont versionnés sur un **dépôt Git partagé**, garantissant la traçabilité des modifications et permettant à chaque membre de l'équipe d'accéder à la dernière version des données propres.

Étape 5 — Uniformisation finale

Un script Python (`scripts/clean_csv.py`) assure une dernière passe d'uniformisation sur l'ensemble des fichiers CSV : cohérence des types, alignement des clés de jointure, vérification de l'intégrité référentielle.

Étape 6 — Chargement en base SQLite

Insertion des CSV normalisés en base **SQLite** via le script `scripts/build_db.py`.

SQLite a été retenu pour sa **légèreté et sa portabilité** : la base est un fichier unique (`mspr.db`), versionnable sur Git, ne nécessitant aucune infrastructure serveur. C'est l'outil adapté à un POC de cette envergure.

Étape 7 — Visualisation et modélisation

Développement du **dashboard interactif** (HTML autonome, Leaflet.js, Chart.js) pour la visualisation des données par département, et mise en place du pipeline de **modélisation prédictive** (voir section 7).

5. Modèle Conceptuel de Données

La base de données est organisée autour d'une table centrale `DEPARTEMENT`, à laquelle se rattachent les 5 tables thématiques par la clé `code_dept`.

`DEPARTEMENT` (`code_dept` PK, `libelle_dept`)


├─< `CHOMAGE` (`code_dept` FK, `annee`, `taux_chomage_moyen`, `taux_chomage_min`, `taux_chomage_max`, `nb_trimestres`)

├─< `DEMOGRAPHIE` (`code_dept` FK, `annee`, `nb_arrondissement`, `nb_canton`, `nb_commune`, `pop_municipale`, `pop_totale`)

├─< `CRIMINALITE` (`code_dept` FK, `annee`, `indicateur_clean` PK, `indicateur`, `unite_de_compte`, `nombre`, `taux_pour_mille`, `insee_pop`)

├─< `ELECTION` (`code_dept` FK, `nom` PK, `prenom`, `sexe`, `inscrits`, `abstentions`, `votants`, `blancs`, `nuls`, `exprimes`, `voix`, `pct_voix_exp`, ...)

├─< `ENTREPRISES` (`code_dept` FK, `annee`, `bure_total_total`, `bure_total_sarl`, `bure_total_sas_sasu`, ...)



Choix de nommage : - Tables en majuscules, noms explicites en français - Colonnes en snake_case, préfixes par thématique (taux_, pct_, nb_, bure_) - Clés composites pour les tables temporelles : (code_dept, annee) pour CHOMAGE, DEMOGRAPHIE, ENTREPRISES ; (code_dept, annee, indicateur_clean) pour CRIMINALITE

Volume total : ~22 000 lignes réparties sur 6 tables.

6. Exploration des données

Jeu de données analytique


Le pipeline complet est disponible dans le notebook docs/exploration.ipynb : 1.

Un DataFrame consolidé a été construit par jointure des tables sur code_dept, avec les transformations suivantes : - Chômage : dernière valeur annuelle disponible par département - Criminalité : taux moyen toutes catégories sur la dernière année - Démographie : recensement le plus récent - Élections : score par candidat (% suffrages exprimés)

Matrice de corrélation — résultats clés


Paire	Corrélation	Niveau
Chômage → Macron	−0,607	Fort
Mélenchon → vols avec armes	+0,721	Très fort
Zemmour → homicides	+0,573	Fort
Le Pen → vols sans violence	−0,469	Modéré

Paire	Corrélation	Niveau
Le Pen ↔ Macron	−0,52	Fort (opposition)




Heatmap matrice de corrélation *Heatmap* — *corrélations entre indicateurs socio-économiques et résultats électoraux*

Distribution des variables



Histogrammes des distributions *Histogrammes — distribution du chômage, de la criminalité, de la population et des scores électoraux*


Évolution du chômage national



Évolution chômage national 1982-2025 *Courbe — taux de chômage moyen national de 1982 à 2025*

Nuages de points — corrélations visuelles

Corrélations variables socio-éco vs résultats électoraux



Scatter plots corrélations *Scatter plots — 6 paires indicateur / candidat (chômage, criminalité, population × Le Pen, Macron)*

Principaux enseignements

- Le **taux de chômage** est l'indicateur le plus corrélé aux résultats électoraux
- Les **départements urbains** (population élevée) favorisent Macron et pénalisent Le Pen
- La **criminalité agrégée** corrèle peu : l'effet est plus fin par type d'infraction
- Les deux candidats du 2ème tour s'opposent nettement au niveau départemental ($R = -0,52$)

7. Modèles prédictifs testés

Approche : apprentissage supervisé par régression

L'objectif est de prédire, à partir des indicateurs socio-économiques d'un département, le % **de voix exprimées** d'un candidat au premier tour d'une élection présidentielle. Un modèle indépendant est entraîné pour chacun des 4 candidats principaux (MACRON, LE PEN, MÉLENCHON, ZEMMOUR).

Variable cible (Y) : % de voix exprimées par candidat (régression continue)

Variables explicatives (X) — 9 features, agrégées sur 2016–2021 : - chômage_moyen — taux de chômage moyen annuel - crim_cambriolages, crim_homicides, crim_trafic_stupefiants - crim_violences_hors_famille, crim_violences_sexuelles - crim_vols_sans_violence, crim_vols_avec_armes - nb_entreprises — nombre total d'entreprises


Validation : Cross-validation 5-fold sur les 94 départements. Le meilleur modèle est sélectionné par candidat sur la base du R^2 moyen.

Modèles comparés


Modèle	Type	Avantages	Limites
Régression Ridge	Régression linéaire régularisée	Simple, interprétable, stable sur petit dataset	Suppose des relations linéaires entre features et score
Random Forest	Ensemble de 200 arbres de régression	Robuste, capture la non-linéarité, fournit la feature importance	Moins interprétable, variance plus élevée sur 94 obs.
XGBoost	Gradient boosting (200 estimateurs)	Haute performance, gère les valeurs aberrantes	Risque de surapprentissage sur un faible nombre d'observations

Implémentation

Le pipeline complet est disponible dans le notebook docs/modele_predictif.ipynb.
 Construction des features par agrégation départementale (moyennes 2016–2021)
 2. Entraînement et évaluation cross-validée (5-fold) des 3 modèles × 4 candidats
 3. Sélection automatique du meilleur modèle par candidat (critère : R^2 moyen)
 4. Application des modèles aux features des années 2023, 2024, 2025



Comparaison R^2 et MAE des 3 modèles *Graphique comparatif — R^2 et MAE des 3 modèles × 4 candidats (cross-val 5-fold)*



Feature importance Random Forest *Importance relative des variables selon le Random Forest — par candidat*


8. Résultats et visualisations

Dashboard interactif

Un dashboard HTML autonome ([dashboard/index.html](#)) a été développé, accessible sans serveur, proposant trois vues :

Vue 1 — Carte & Indicateurs


Carte choroplèthe de la France par département, colorée selon l'indicateur sélectionné (chômage, criminalité, population, entreprises). Clic sur un département → panneau latéral affichant l'ensemble de ses indicateurs, un historique du chômage depuis 2010, et les résultats électoraux T1 2022.



Dashboard Vue 1 — Carte indicateurs *Dashboard — carte choroplèthe avec panneau latéral département (ex : Ain)*

Vue 2 — Résultats T1 2022


Carte colorée par candidat en tête ou par pourcentage d'un candidat sélectionné. Bar chart des résultats nationaux agrégés. Détail par département au clic.



Dashboard Vue 2 — Résultats T1 *Dashboard — carte des résultats T1 2022 colorée par candidat gagnant*

Vue 3 — Corrélations

Nuages de points (scatter plots) pour chaque paire indicateur / candidat, avec calcul du R^2 affiché. Permet d'identifier visuellement les variables les plus explicatives.



Dashboard Vue 3 — Corrélations *Dashboard — scatter plots avec R^2 calculé par paire indicateur / candidat*

Prédictions à 1, 2 et 3 ans

Les features réelles disponibles pour 2023, 2024 et 2025 (chômage, criminalité, entreprises) sont injectées dans le meilleur modèle de chaque candidat afin de simuler des scores nationaux si une élection avait lieu ces années-là.


Horizons de prédiction : - T+1 = 2023 — premières projections post-élection de référence - **T+2 = 2024** — scénario à moyen terme - **T+3 = 2025** — horizon stratégique cible d'ElectioAnalytics

Les résultats sont produits à deux niveaux : score national moyen (agrégé sur 94 départements) et score par département (pour le ciblage territorial).

Scores nationaux moyens prédits (% voix exprimées) :

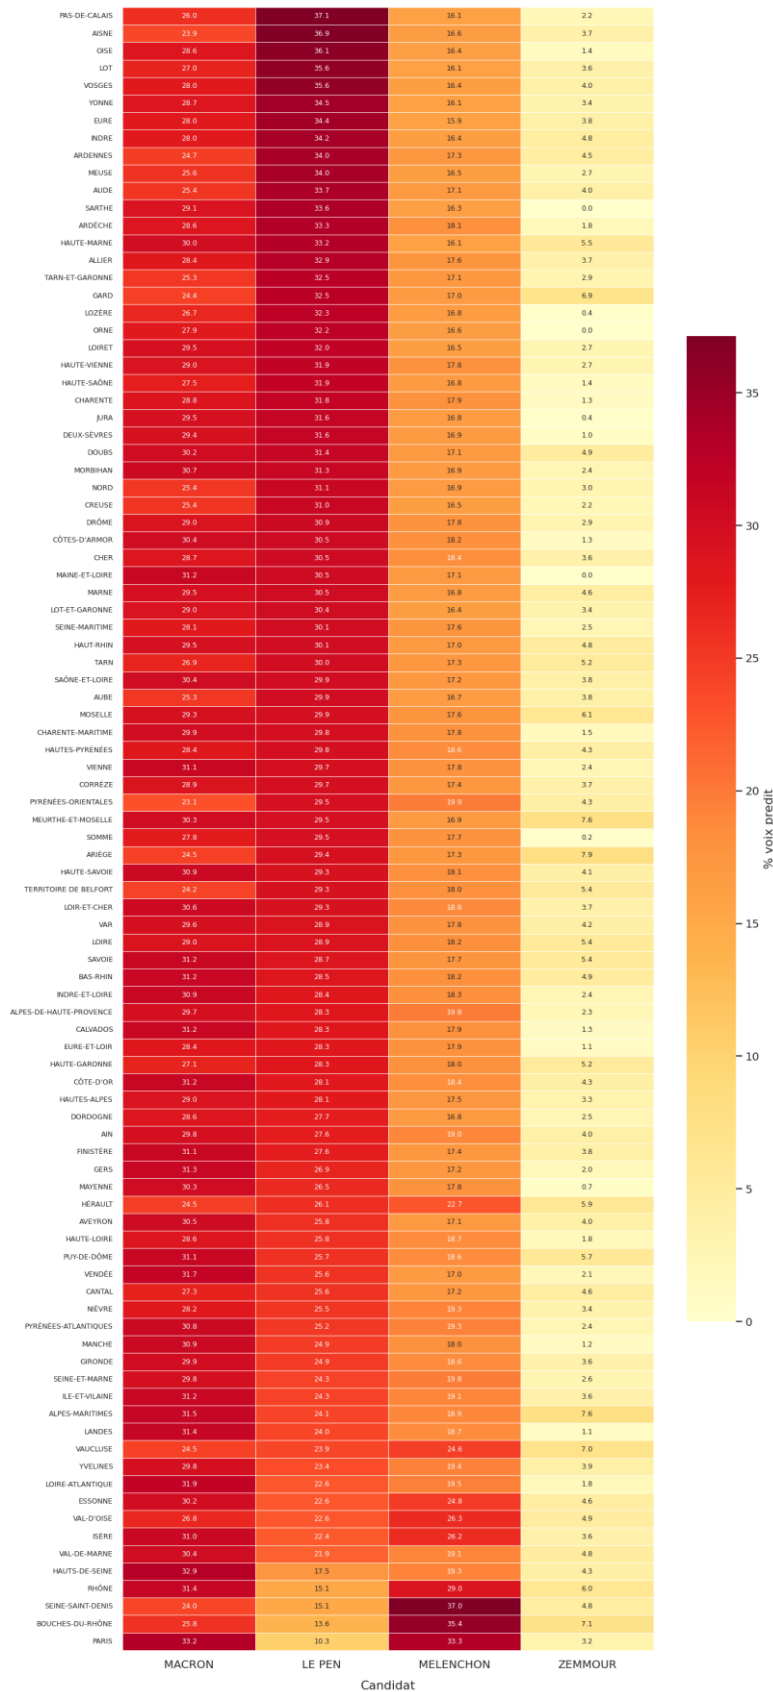
Candidat	Réel 2022	T+1 2023	T+2 2024	T+3 2025
MACRON	26,7 %	29,2 %	29,1 %	28,8 %
LE PEN	25,1 %	27,8 %	27,9 %	28,6 %
MÉLENCHON	20,0 %	18,9 %	18,7 %	18,7 %
ZEMMOUR	7,0 %	4,5 %	3,9 %	3,5 %

Lecture : le modèle projette un **resserrement MACRON/LE PEN** à l'horizon 2025 (28,8 % vs 28,6 %), un MÉLENCHON stable autour de 18,7 % et un ZEMMOUR en érosion continue, cohérent avec la recomposition du bloc national.



Courbe temporelle T / T+1 / T+2 / T+3 *Visualisation 1* — Score nationale réel 2022 + prédictions 2023/2024/2025 avec bande d'incertitude (± 1 écart-type inter-départements)

Heatmap des scores predicts 2025 (T+3)
par departement et candidat — trie par LE PEN



Heatmap des scores prédits 2025 par département *Visualisation 2 — Heatmap T+3 (2025) : scores prédits par département × candidat, triés par score Le Pen décroissant*

Diagramme de probabilité — Incertitude par horizon de prédiction
(chaque barre = 1 arbre RF ; plus large = plus incertain)




Diagramme de probabilité — incertitude par horizon *Visualisation 3 — Distribution des prédictions des 200 arbres RF par horizon (T+1/T+2/T+3) : plus la courbe est large, plus l'incertitude est grande*

9. Accuracy — pouvoir prédictif

Définition des métriques utilisées

Les modèles étant de **régression** (prédiction du % de voix), trois métriques sont calculées en cross-validation 5-fold :

- **R²** (coefficient de détermination) : proportion de variance du score électoral expliquée par le modèle. Valeur entre 0 (nul) et 1 (parfait). **Seuil retenu : R² > 0,40**, acceptable compte tenu d'une seule élection en base d'entraînement.

$$R^2 = 1 - (SS_{\text{résiduel}} / SS_{\text{total}})$$

- **MAE** (Mean Absolute Error) : erreur absolue moyenne en points de %, directement lisible sans connaissances statistiques. **Seuil retenu : MAE < 3 pts%**.
- **RMSE** (Root Mean Square Error) : racine de l'erreur quadratique moyenne, pénalise davantage les gros écarts que la MAE.

Limites et perspectives

Les R^2 obtenus sont modestes, pour une raison structurelle : le modèle est entraîné sur **une seule élection** (2022). La variabilité des scores électoraux entre départements est en partie liée à des facteurs locaux non capturés par les 9 features. L'intégration des scrutins 2012 et 2017 (si fournis par Electio-Analytics) permettrait d'augmenter significativement la base d'entraînement et d'améliorer les R^2 .

Tableau récapitulatif

Candidat	Meilleur modèle	R^2 (CV 5-fold)	MAE (pts%)	RMSE
MACRON	Random Forest	0.366	2.33	2.93
LE PEN	XGBoost	0.545	2.92	3.89
MÉLENCHON	Random Forest	0.189	2.45	3.64
ZEMMOUR	Ridge	0.312	0.92	1.15

Seuils retenus : $R^2 > 0,40$ • MAE < 3 pts% (gras = objectif atteint)

- **LE PEN** est le candidat le mieux prédit ($R^2 = 0,545 > \text{seuil}$, MAE = 2,92 ✓)
- **MACRON** atteint la MAE cible (2,33) mais reste légèrement sous le R^2 seuil (0,366)
- **MÉLENCHON** et **ZEMMOUR** ont des R^2 modestes — MÉLENCHON est difficile à modéliser par indicateurs socio-économiques seuls ; ZEMMOUR a une faible variance nationale (std = 1,6%), ce qui rend la MAE naturellement basse malgré un R^2 limité

Candidat	Modele	R2_mean	R2_std	MAE_mean	MAE_std	RMSE_mean
MACRON	Ridge	0.013	0.468	2.653	0.322	3.798
MACRON	RandomForest	0.366	0.196	2.331	0.241	2.932
MACRON	XGBoost	0.301	0.267	2.349	0.314	3.046
LE PEN	Ridge	0.321	0.532	3.226	0.915	5.258
LE PEN	RandomForest	0.452	0.134	3.278	0.403	4.365
LE PEN	XGBoost	0.545	0.193	2.917	0.426	3.892
MELENCHON	Ridge	-0.074	0.590	2.539	0.614	4.004
MELENCHON	RandomForest	0.189	0.528	2.449	0.572	3.636
MELENCHON	XGBoost	0.111	0.630	2.414	0.567	3.680
ZEMMOUR	Ridge	0.312	0.243	0.924	0.125	1.150
ZEMMOUR	RandomForest	0.291	0.365	0.869	0.145	1.186
ZEMMOUR	XGBoost	0.034	0.773	0.915	0.085	1.268

Comparaison R^2 et MAE — 3 modèles × 4 candidats *Graphique — comparaison de l'accuracy : R^2 et MAE des 3 modèles par candidat (cross-val 5-fold)*

10. Réponses aux questions d'analyse

Quelle donnée est la plus corrélée aux résultats des élections ?

La variable la plus corrélée aux résultats électoraux **varie selon le candidat**. L'analyse de corrélation réalisée dans le notebook (section 4) sur les 94 départements révèle que chaque candidat répond à un profil socio-économique distinct :

Le calcul effectué sur les 94 départements donne les corrélations suivantes (valeur absolue maximale par candidat) :

Candidat	Variable la plus corrélée	Coefficient r	Interprétation
MACRON	chomage_moyen	−0,607	Forte corrélation négative : les départements à fort chômage votent peu Macron
LE PEN	crim_vols_sans_violence	−0,469	Les départements à fort taux de vols votent moins Le Pen (effet urbain inversé)
MÉLENCHON	crim_vols_avec_armes	+0,721	Forte corrélation positive : les zones à haute criminalité

Candidat	Variable la plus corrélée	Coefficient r	Interprétation
			armée — typiquement urbaines défavorisées — votent plus Mélenchon
ZEMMOUR	crim_homicides	+0,573	Corrélation avec la criminalité violente, cohérente avec le positionnement sécuritaire

La variable structurante la plus discriminante toutes tendances confondues est le chômage_moyen ($r = -0,607$ avec Macron), confirmé par la heatmap de corrélations (section 4.1 du notebook). La décomposition par type d’infraction révèle que la criminalité agrégée masque des effets opposés selon le type d’acte.

Définissez le principe d’un apprentissage supervisé

L’apprentissage supervisé est une méthode de machine learning dans laquelle le modèle est **entraîné sur des exemples étiquetés** : pour chaque département, on lui fournit les indicateurs socio-économiques (X) et le résultat électoral correspondant (Y, la valeur à prédire).

Le modèle apprend une **fonction de correspondance** $X \rightarrow Y$ en minimisant l’erreur sur les données d’entraînement. On évalue ensuite sa capacité à **généraliser** sur des données inédites via la cross-validation.

Dans notre cas : - **X (features)** : 9 variables socio-économiques départementales (chômage, 7 indicateurs de criminalité, nb entreprises), agrégées sur 2016–2021 - **Y (cible)** : % de voix exprimées par candidat au T1 2022 (valeur continue — régression) - **Validation** : cross-validation 5-fold sur les 94 départements — le modèle est entraîné 5 fois, chaque fois sur 80 % des données, et évalué sur le 20 % restant

L’apprentissage est dit “supervisé” car le modèle dispose de la vérité terrain (résultats 2022) lors de l’entraînement. Pour les prédictions 2023/2024/2025, on injecte les features réelles de ces années dans le modèle appris — c’est la phase d’inférence, sans supervision.

Comment définissez-vous le degré de précision (accuracy) de votre modèle ?

Nos modèles produisant des valeurs continues (% de voix), nous n'utilisons pas l'accuracy au sens de la classification. Le **degré de précision** est mesuré par trois métriques complémentaires :

R² — coefficient de détermination

$R^2 = 1 - (\text{somme des erreurs au carré} / \text{variance totale du score})$

Valeur entre 0 et 1. Un R² de 0,60 signifie que le modèle explique 60 % de la variance des scores électoraux entre départements. Seuil acceptable retenu : **R² > 0,40**.

MAE — Mean Absolute Error

$MAE = \text{moyenne}(|\text{score_prédit} - \text{score_réel}|)$ [en points de %]

Directement lisible : une MAE de 2,5 signifie que le modèle se trompe en moyenne de 2,5 points de pourcentage. Seuil acceptable retenu : **MAE < 3 pts%**.

RMSE — Root Mean Square Error Pénalise davantage les gros écarts que la MAE. Utilisé en complément pour détecter les départements “outliers” où le modèle est particulièrement en difficulté.

Note : les R² restent modestes car le modèle est entraîné sur une seule élection (94 observations). Ils seront significativement améliorés en intégrant les scrutins de 2012 et 2017.

11. Recommandations

Sur la base des résultats de l'exploration, nous formulons les recommandations suivantes pour Electio-Analytics :

- 1. Priorité au chômage et à l'urbanisation** Ces deux variables constituent le socle explicatif le plus robuste. Tout modèle de ciblage électoral devrait les intégrer en priorité.
- 2. Affiner l'indicateur criminalité** Le taux agrégé est peu discriminant. Une décomposition par type d'infraction (violences, trafic de stupéfiants) apporterait un signal plus fin, notamment pour les candidats à profil sécuritaire.
- 3. Enrichir avec le taux de pauvreté** Non intégré dans ce POC par manque de données harmonisées, cet indicateur est identifié en littérature comme fortement prédictif des votes de contestation. Son intégration est prioritaire pour la phase de production.

4. Passer à une maille temporelle Ce POC exploite un instantané (élections 2022). Pour des prévisions à 1–3 ans, il faudra modéliser l'évolution des indicateurs dans le temps et les corrélérer avec les variations de l'intention de vote via des sondages.

5. Valider sur plusieurs scrutins Entraîner le modèle sur 2012, 2017 et valider sur 2022 permettrait de tester la stabilité temporelle des corrélations et d'accroître la fiabilité des projections.