



PLAN D'ACTION – MSPR BLOC 3 (POC Big Data)



Objectif

Construire un **POC prédictif fiable, industrialisable et documenté**, prêt à être présenté au jury et exploitable par l'entreprise.



PHASE 1 – Cadrage stratégique (Jour 1–2)



Choix de la zone géographique

- Identifier 2–3 zones candidates
- Vérifier disponibilité des données
- Évaluer volumétrie et cohérence
- Justifier le choix (représentativité + faisabilité)



Livrable interne :

- Note de justification (1 page)
-



Définition des indicateurs

Sélectionner :

- Résultats électoraux historiques
- Taux de chômage
- Indicateurs de sécurité
- Démographie : antoine
- Niveau de pauvreté - kevin
- Activité économique

- (Éventuellement réseaux sociaux)

🚩 Objectif :

Limiter à **5–8 variables fortes et cohérentes**

📅 PHASE 2 – Architecture & Data Engineering (Jour 3–7)

3 Conception de l'architecture data

Schéma cible :

Sources → ETL → Base structurée → Analyse → Modèle → Visualisation

Définir :

- Format de stockage (PostgreSQL recommandé)
- Schéma clair des tables
- Clés primaires
- Relations

🚩 Livrable :

- Schéma conceptuel (MCD simplifié)
-

4 Mise en place du pipeline ETL

Étapes :

- Extraction (API / CSV / scraping si nécessaire)
- Nettoyage (valeurs manquantes, doublons)
- Normalisation (formats dates, pourcentages)
- Transformation (agrégation par année)
- Chargement en base

🚩 Objectif :
Script automatisé reproductible

5 Vérification qualité des données

- Cohérence temporelle
 - Valeurs aberrantes
 - Traçabilité des sources
 - Documentation des transformations
-

📅 PHASE 3 – Analyse exploratoire (Jour 8–10)

6 Analyse descriptive

Produire :

- Histogrammes
- Matrice de corrélation
- Heatmaps
- Graphiques temporels

🚩 Question clé :
👉 Quelle variable est la plus corrélée aux résultats électoraux ?

📅 PHASE 4 – Modélisation prédictive (Jour 11–15)

7 Préparation dataset ML

- Séparation Train/Test (70/30)
 - Feature scaling si nécessaire
 - Encodage
-

Tester plusieurs modèles

Par exemple :

- Régression logistique
- Random Forest
- Gradient Boosting

Comparer :

- Accuracy
- Precision
- Recall
- F1-score

 Choisir le modèle le plus robuste

Projection 1–3 ans

Simuler :

- Scénario optimiste
- Scénario stable
- Scénario dégradé

Produire :

- Courbes
- Probabilités
- Cartes de projection

1 PHASE 5 – Industrialisation & Documentation (Jour 16–20)

10 Structuration des livrables

1. Dossier de synthèse

Inclure :

- Justification zone
- Indicateurs
- Architecture
- ETL
- Modèles testés
- Résultats
- Accuracy
- Limites
- Recommandations

2. Dataset final nettoyé

- Export SQL ou CSV propre
- Version optimisée

3. Code commenté

- Notebook Jupyter propre
 - README clair
 - Explications pédagogiques
-

4. Visualisations claires

- Lisibles pour non-techniciens
 - Orientées décision
-

PHASE 6 – Préparation soutenance (Jour 21–25)

1 Structure de présentation (20 min)

Slide 1 – Problématique

Slide 2 – Zone choisie

Slide 3 – Données retenues

Slide 4 – Architecture & ETL

Slide 5 – Analyse exploratoire

Slide 6 – Modèles testés

Slide 7 – Modèle retenu + accuracy

Slide 8 – Projections

Slide 9 – Recommandations stratégiques

Slide 10 – Passage à l'échelle

Répartition conseillée dans l'équipe (4 personnes)

 **Data Engineer**

- ETL

- Base
- Qualité données

Data Analyst

- Analyse exploratoire
- Corrélations
- Visualisations

Data Scientist

- Modèles ML
- Évaluation
- Projections

Architecte / Lead

- Architecture globale
- Documentation
- Coordination
- Soutenance

Points critiques à ne pas rater

- Justification claire du choix géographique
 - Pipeline automatisé (pas juste des fichiers manuels)
 - Comparaison de plusieurs modèles
 - Explication pédagogique de l'accuracy
 - Visualisations compréhensibles
 - Dossier structuré
-



Stratégie pour impressionner le jury

- ✓ Comparaison de 2–3 modèles
 - ✓ Discussion des biais et limites
 - ✓ Justification business (pas uniquement technique)
 - ✓ Vision de mise à l'échelle nationale
 - ✓ Mention RGPD & sécurité
-

🎯 Résultat attendu

Un POC :

- Scientifiquement cohérent
- Méthodologiquement rigoureux
- Techniquement propre
- Stratégiquement pertinent
- Présentable à un investisseur